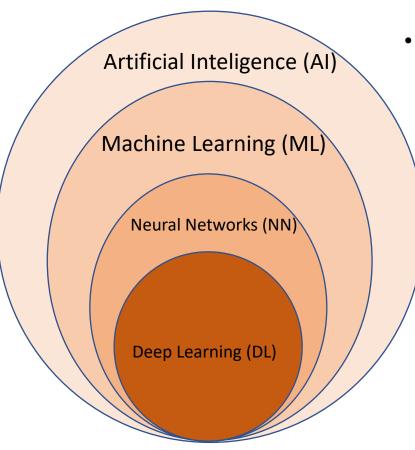
Anatomía e implementación de un método numérico de 'Deep Learning' por medio de optimización estocástica y sus aplicaciones industriales

Dr. Alberto Santamaria Pang

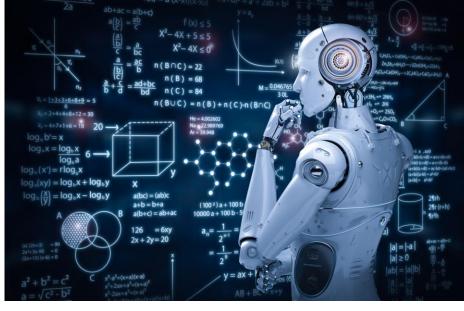
Contenido

- Introducción
- Estructura de algoritmos de aprendizaje
- Aplicaciones
 - Manufactura
 - Turbinas de avión
 - Análisis de imágenes medicas y biomédicas
 - Radiología
 - Patología Molecular

Deep Learning



Habilidad de una maquina de imitar inteligencia humana



(2159×1389) (parentology.com)

- Automáticamente aprende de 'errores'
- Inspirados en modelos biológicos

- Redes neuronales de aprendizaje profundo
 - 'Deep Neural Networks'

AUTOMATIC THREE-DIMENSIONAL

MORPHOLOGICAL RECONSTRUCTION OF NEURONS

A Dissertation

Presented to

the Faculty of the Department of Computer Science

University of Houston

In Partial Fulfillment

of the Requirements for the Degree

Doctor of Philosophy

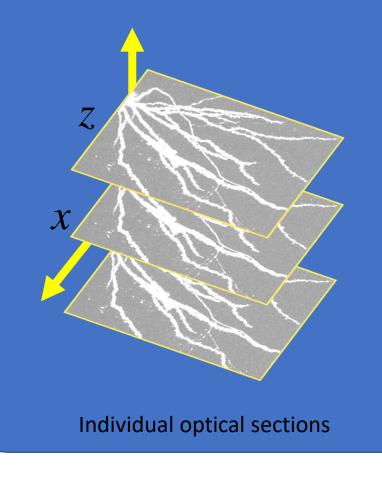
By

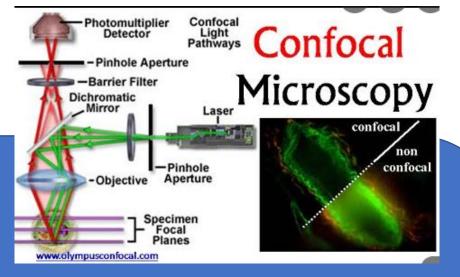
Alberto Santamaría-Pang

December 2007

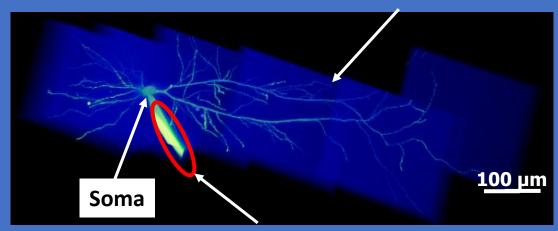


3D Optical Imaging





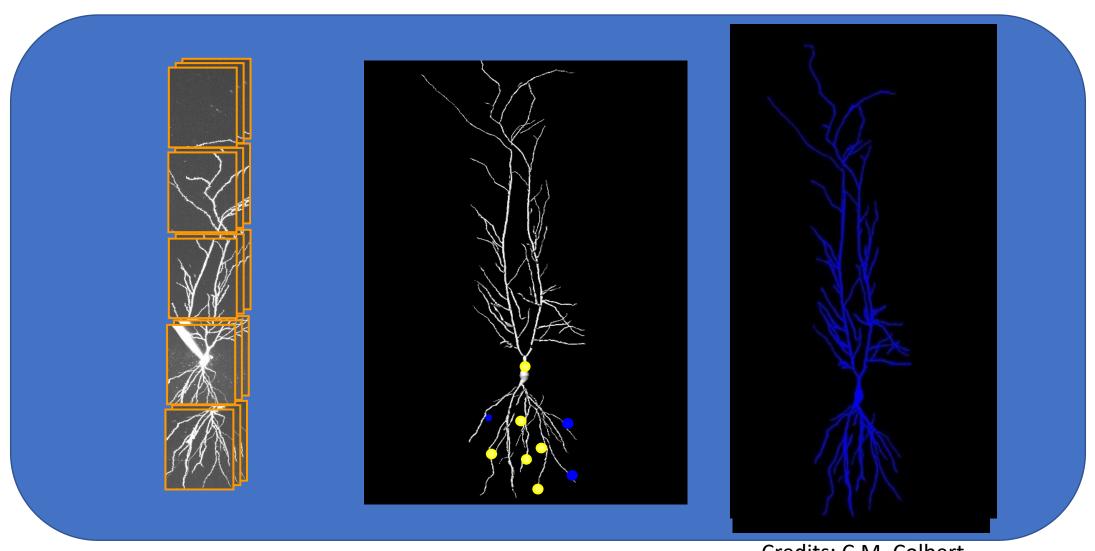
Dendrites



Pipette

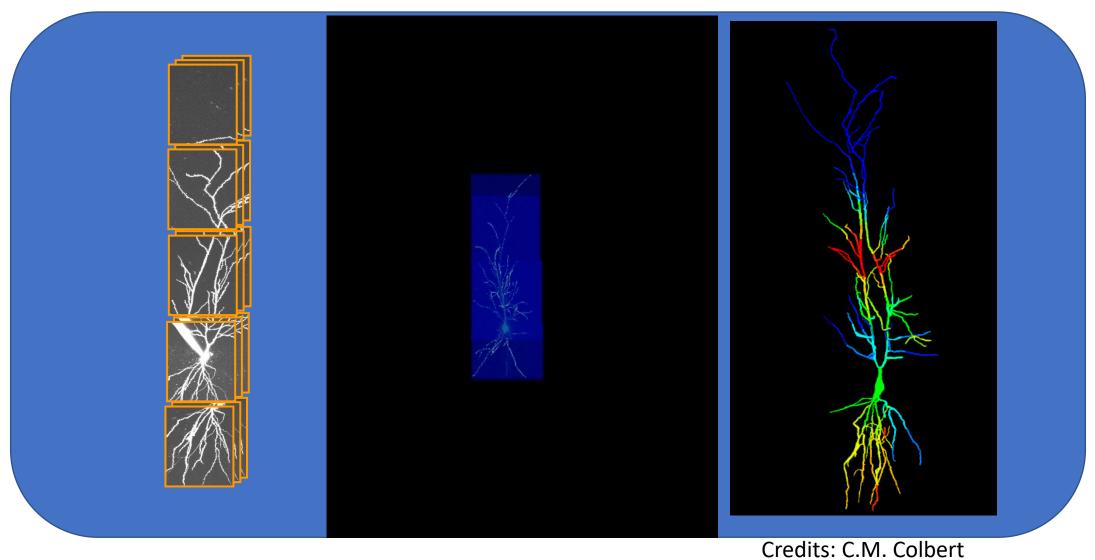
Stacks of optical sections

Motivación – Modelado Neuronal



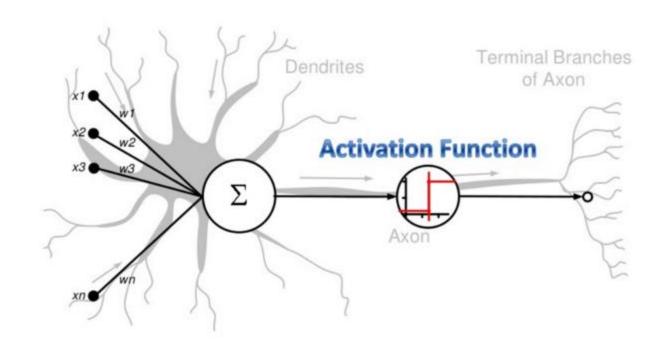
Credits: C.M. Colbert

Motivación – Modelado Neuronal





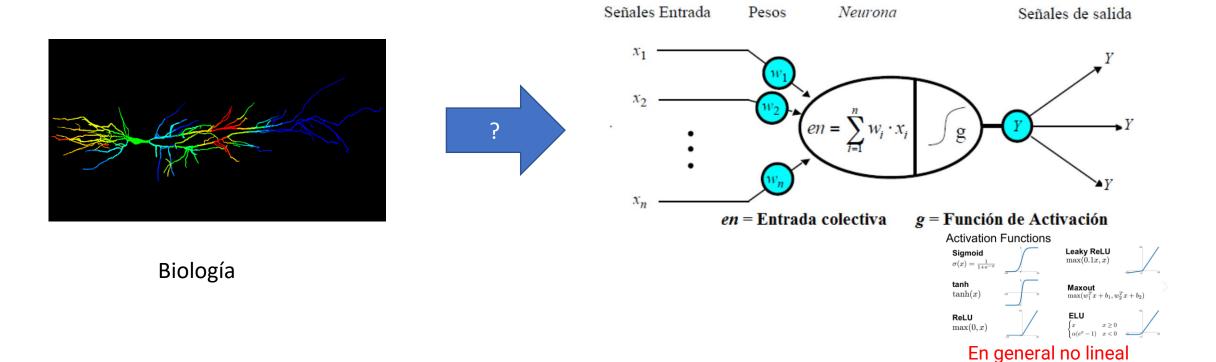




McCulloch, Warren; Walter Pitts (1943). "A Logical Calculus of Ideas Immanent in Nervous Activity". Bulletin of Mathematical Biophysics. **5** (4): 115–133. doi:10.1007/BF02478259.

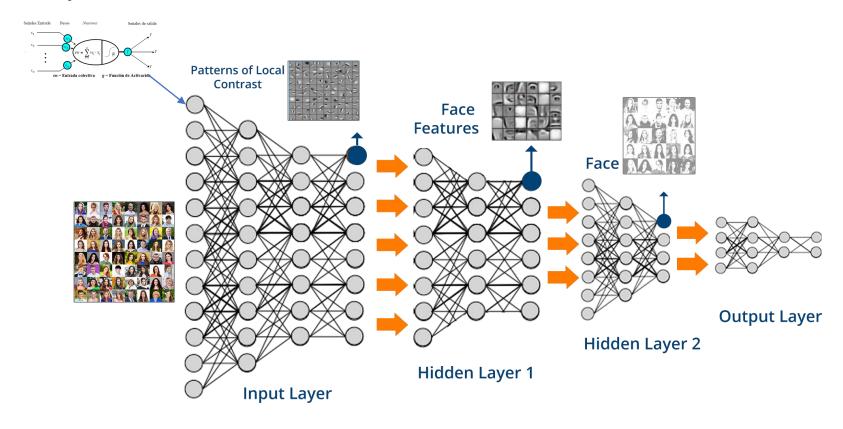
Motivación – Modelado Neuronal

Modelo simplificado de una neurona



red neuronal, activacion de una neurona - Bing images

Concepto de Red Neuronal



Modelo: $f_w(X) \approx Y$

ResNet-50 tiene mas 23 millones de parámetros ¿Cómo optimizar?

Descenso por Gradiente



Modelo:

$$f_w(X) \approx Y$$

Función de costo *J* :

$$J(w) = \frac{1}{N} \sum_{i=1}^{N} ||f_w(x_i) - y_i||^2$$

dos veces continuamente diferenciable

Minimizar:

$$\min_{w} J(w)$$

Descenso por gradiente:

$$w^{t+1} = w^t - \alpha \nabla J(w^t)$$

Dos problemas:

- i) convexidad
- ii) limitación de procesamiento y memoria





Descenso por gradiente descenso de gradiente estocástico (SGD)

Idea: Vamos a seleccionar un subconjunto de todos los datos y vamos a calcular el gradiente:

$$\mathsf{E}_{v\sim D}\left[J_v(w^t)\right]$$

v es una muestra aleatoria de una distribución de probabilidad.

Se puede expresar como:

$$w^{t+1} = w^t - \alpha \nabla J_{v_t}(w^t)$$





1)
$$J_v$$
 es L-'smooth' (convexidad)
 $E_{v\sim D}\left[||\nabla J_v(w) - \nabla J_v(w^*)||\right] \le 2L\left[J_v(w) - J_v(w^*)\right]$

2) El 'ruido' estocástico del gradiente es finito:

$$\sigma^2 = \mathsf{E}_{v \sim D} [||J_v(w^{t+1})||]$$

Entonces:

$$\mathsf{E}_{v\sim D}\left[J_v(w^{t+1})\mid w^t\right] \leq \frac{1}{\alpha(t+t^0)}, \quad \alpha = \frac{2\mu}{L^2+\sigma^2}, \, \mu \text{ constante}$$

Interpretación: Cuanto más fuerte es la convexidad, más rápida es la convergencia.

Convexidad

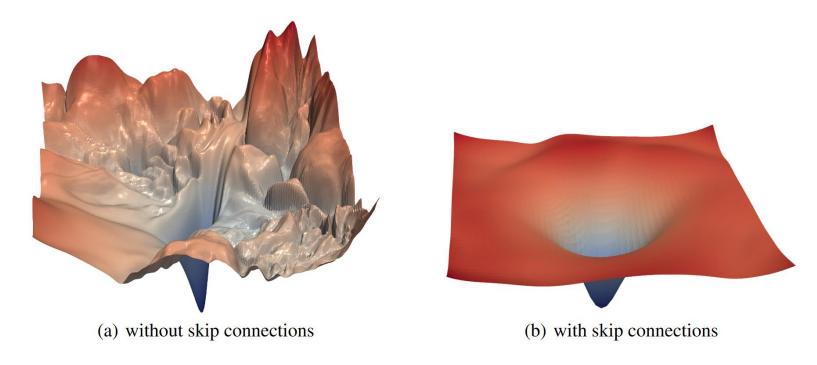


Figure 1: The loss surfaces of ResNet-56 with/without skip connections. The proposed filter normalization scheme is used to enable comparisons of sharpness/flatness between the two figures.



Li, "Visualizing the Loss Landscape of Neural Nets", NeurIPS 2018

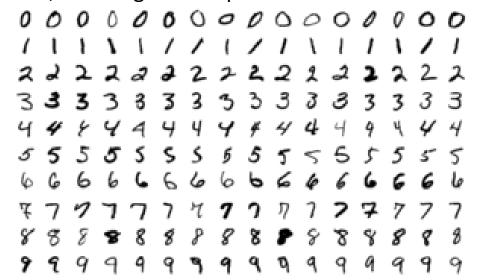
Demo



Clasificación de imágenes de dígitos del 0 al 9

Datos:

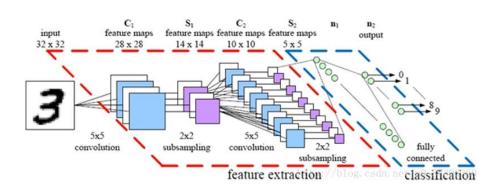
- Creados en 1998
- Modified National Institute of Standards and Technology (MNIST)
- 60,000 imágenes de entrenamiento
- 10,000 imágenes de prueba



Imágenes monocromáticas de 8bits:

cada pixel tiene 256 valores

CNN

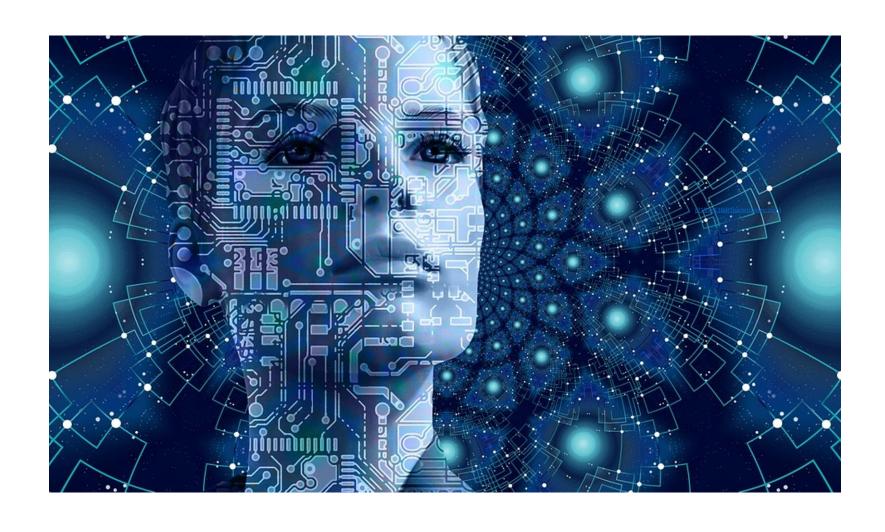


$$f_w(X) \approx Y$$

Créditos: Hoe Jiun Tian

https://github.com/jiuntian/pytorch-mnist-example/blob/master/pytorch-mnist.ipynb

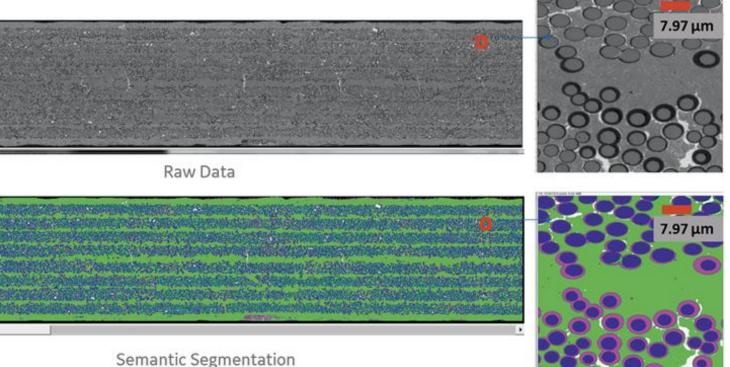
Aplicaciones



Control de Calidad en Manufacturación







Jim Steibe, "Ceramic matrix composites taking flight at GE Aviation", American Ceramic Society Bulletin, Vol. 98, No. 3, 2019

Kareem S. Aggour, et al, "Artificial intelligence/machine learning in manufacturing and inspection: A GE perspective", MRS Bulletin, 44(7), 545-558. doi:10.1557/mrs.2019.157

Radiología: Segmentación de tumor cerebral



Tumor Present			Tumor Absent		
CS_6669 Slice 13 357, 6563, 3956, *	DU_5855 Slice 16 5886, 4043, 5114, *	DU_A5TW Slice 20 5886, 3101, 5114, *	CS_5396 Slice 7 657, 653, 6531, *	HT_7856 Slice 29 657, 653, 6613 *	HT_A616 Slice 7 657, 653, 6531, *
Large Area			Small Area		
DU_7018 Slice 21 7313, 4626, 8872, *	HT_7694 Slice 12 8584, 4043, 5114, *	HT_7882 Slice 18 6670, 3578, 525, *	DU_7306 Slice 25 657, 2863, 2863, *	FG_7637 Slice 30 657, 653, 6613, *	DU_8166 Slice 29 657, 653, 6613, *

Patología Molecular: Cuantificar de células del sistema inmunológico



uploads/Pathology-Al-poster-web-1024x768.png

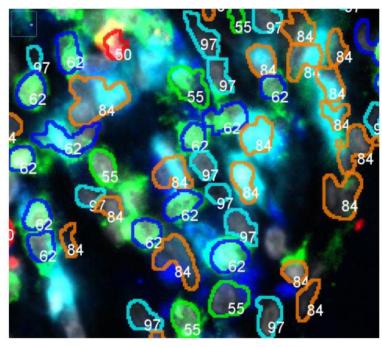


Fig. 4: Color composite image: CD20 (B-Cell), CD3 (T-Cell), CD68 (Macrophage), Claudin1 and DAPI (Cell Nuclei), in Red, Green, Blue, Cyan and Gray respectively. The segmented stroma nuclei is overlaid with the symbol identifier for each cell. We observe that the different cell phenotype markers are associated with distinct symbols, but are same for the cells with the same marker. The symbols generated correspond to Experiment 1 in Table 1 and Fig. 3(a).

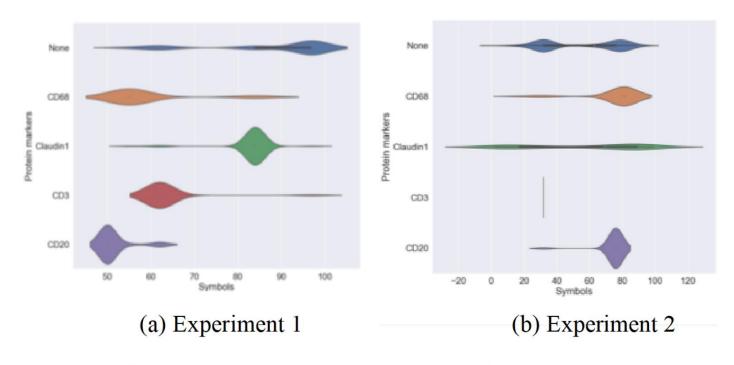


Fig. 3: Violin plots of the distributions of symbols from 1-100 with respect to the protein markers in (a) Experiment 1 and (b) Experiment 2

Conclusión

• Actualmente es el mejor momento de la historia de la humanidad para ser matemático.

Agradecimientos

- Mat. Rafael Davis Velati
- Dr. Homero Ríos Figueroa
- M.I.A. Patricia González Gaspar

• Profesores de la Facultad de Matemáticas

• Compañeros de generación